

**FACULDADE DE TECNOLOGIA DE SÃO JOSÉ DOS CAMPOS
FATEC PROFESSOR JESSEN VIDAL**

GIULIANO GIMENEZ AMORIM

**UTILIZAÇÃO DE DEEP LEARNING PARA O AUXÍLIO NA
DETECÇÃO DE CÂNCER DE PELE**

São José dos Campos
2019

GIULIANO GIMENEZ AMORIM

**UTILIZAÇÃO DE DEEP LEARNING PARA O AUXÍLIO NA
DETECÇÃO DE CÂNCER DE PELE**

Trabalho de Graduação apresentado à
Faculdade de Tecnologia de São José dos
Campos, como parte dos requisitos
necessários para a obtenção do título de
Tecnólogo em Banco de Dados.

Orientador: Me. Giuliano Araujo Bertoti

São José dos Campos
2019

Dados Internacionais de Catalogação-na-Publicação (CIP)
Divisão de Informação e Documentação

AMORIM, Giuliano Gimenez
Utilização de Deep Learning para o auxílio na detecção de câncer de pele.
São José dos Campos, 2019.
40f.

Trabalho de Graduação – Curso de Tecnologia em Banco de Dados.
FATEC de São José dos Campos: Professor Jessen Vidal, 20XX.
Orientador: Me. Giuliano Araujo Bertoti

1. Deep Learning. 2. Câncer de pele. 3. Redes neurais. I. Faculdade de Tecnologia. FATEC de São José dos Campos: Professor Jessen Vidal. Divisão de Informação e Documentação. II. Título

REFERÊNCIA BIBLIOGRÁFICA

AMORIM, Giuliano Gimenez. **Utilização de Deep Learning no Auxílio na Detecção de Câncer de Pele**. 2019. 40f. Trabalho de Graduação - FATEC de São José dos Campos: Professor Jessen Vidal.

CESSÃO DE DIREITOS

NOME(S) DO(S) AUTOR(ES): Giuliano Gimenez Amorim.

TÍTULO DO TRABALHO: Utilização de Deep Learning no Auxílio na Detecção de Câncer de Pele.

TIPO DO TRABALHO/ANO: Trabalho de Graduação/2019.

É concedida à FATEC de São José dos Campos: Professor Jessen Vidal permissão para reproduzir cópias deste Trabalho e para emprestar ou vender cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte deste Trabalho pode ser reproduzida sem a autorização do autor.

Giuliano Gimenez Amorim
Rua Goiânia, 194, Parque Industrial
12235-625, São José dos Campos – São Paulo

GIULIANO GIMENEZ AMORIM

**UTILIZAÇÃO DE DEEP LEARNING PARA O AUXÍLIO NA
DETECÇÃO DE CÂNCER DE PELE**

Trabalho de Graduação apresentado à
Faculdade de Tecnologia de São José dos
Campos, como parte dos requisitos
necessários para a obtenção do título de
Tecnólogo em Banco de dados.

Me. Giuliano Araujo Bertoti – FATEC São José dos Campos

Titulação, Nome do Componente da Banca - Sigla da Instituição

Titulação, Nome do Componente da Banca - Sigla da Instituição

____/____/____

DATA DA APROVAÇÃO

Dedico este trabalho a todos os professores, pois foram eles que transmitiram o conhecimento necessário para aqui hoje estar desenvolvendo este trabalho.

AGRADECIMENTOS

Agradeço a todos os professores da Faculdade de Tecnologia de São Paulo – Professor Jessen Vidal, pela imensa oportunidade de ser desafiado nas questões que estavam mais pendentes na minha carreira profissional.

Diretamente, agradeço o orientador desse trabalho, Professor Me. Giuliano Araujo Bertoti por ter me incentivado a abordar esse tema e desafiar-me com este trabalho no qual supera as expectativas de um trabalho de conclusão do curso.

Agradeço, também, o Professor Me. Eduardo Sakaue no qual foi meu mentor na vida profissional e proporcionou novos desafios a serem experimentados.

Além disso, gostaria de agradecer à minha mãe Maria Cristina Gimenez Amorim, também professora, por sempre ter acreditado no meu potencial como aluno.

E, por fim, gostaria de agradecer à minha esposa Carla e à minha enteada Gabriela, por terem sido pacientes e terem me apoiado durante essa jornada de 3 anos.

“Inteligência é a habilidade de se adaptar às mudanças.”

Stephen Hawking

RESUMO

As redes neurais estão fazendo parte do dia a dia da humanidade que tem acesso a tecnologias modernas na internet. A utilização deste tipo de tecnologia poderá ter papel significativo no avanço da medicina e até mesmo salvar vidas. Este trabalho mostrará um cenário como este onde se aplicaria a utilização de uma rede neural no auxílio de detecções de doenças de pele.

Palavras-Chave: rede neural; câncer; medicina; melanoma; não-melanoma;

ABSTRACT

Neural networks is present of the daily life of humanity that has access to modern technologies. The use of this kind of technology could be a significant role in advance of the medicine and even saving lives. This work will show a scenario where the use of neural networks would be applied to aid skin disease detection.

Keywords: neural networks; cancer; medicine; melanoma; non-melanoma;

LISTA DE FIGURAS

Figura 1. à esquerda, uma lesão benigna (não câncer) e, à direita, uma lesão maligna (câncer).	16
Figura 2. a evolução de uma célula cancerígena	18
Figura 3. a evolução da inteligência artificial.....	21
Figura 4. Constituintes da célula neuronal	22
Figura 5. Exemplo de funcionamento de um tipo de Rede Neural Artificial.....	23
Figura 6. Classificação da imagem.....	25
Figura 7. Fluxo da arquitetura do sistema	28
Figura 8. Videodermatoscópio sendo utilizado para captura de imagens	29
Figura 9. Fluxograma da ingestão de dados	31
Figura 10. Esquema de <i>backpropagation</i>	32
Figura 11. rede neural treinada no modelo LeCun reconhecendo caracteres.....	33
Figura 12. Estrutura de uma API Rest	34
Figura 13. diagrama de classe do projeto cancer-consult-api.....	35
Figura 14. Fluxo da interface web	36

LISTA DE TABELAS

Tabela 1. Características de uma lesão de pele cancerígena.	20
Tabela 2. Relação dos endpoints utilizados na API do ISIC.	30
Tabela 3. classes do projeto cancer-consult-api	35

LISTA DE ABREVIATURAS E SIGLAS

DL	<i>Deep Learning</i>
DL4J	<i>DeepLearning4J</i>
RN	Rede Neunal
CNN	<i>Covolutional Neural Network</i>
API	<i>Application Programming Interface</i>
HTTP	<i>HyperText Transfer Protocol</i>
Rest	<i>Representational State Transfer</i>

LISTA DE SÍMBOLOS

Σ Somatória

SUMÁRIO

1. INTRODUÇÃO	15
1.1. Problema em Estudo	15
1.2. Proposta de Solução.....	15
2. REVISÃO DA LITERATURA	18
2.1. O câncer de pele.....	18
2.1.1. Câncer de pele não melanoma	19
2.1.2. Câncer de pele não melanoma	19
2.1.3. Detecção do câncer de pele.....	19
2.2. A aprendizagem profunda.....	20
2.2.1. Rede Neural Artificial.....	21
2.2.2. Rede Neural Convulocional.....	24
2.3. Soluções semelhantes	26
3. DESENVOLVIMENTO DO TRABALHO.....	28
3.1. Arquitetura do sistema.....	28
3.2. Ingestão dos dados (<i>dataset-downloader</i>)	28
3.3. Treinamento das redes neurais (<i>cnn</i>)	31
3.3.1. Modelo LeNet.....	32
3.3.2. Gradiente descendente	33
3.4. <i>API Rest (cancer-consult-api)</i>	34
3.5. Interface de usuário (<i>cancer-consult-ui</i>).....	36
4. RESULTADOS E DISCUSSÕES	37
4.1. Outros <i>frameworks</i> de redes neurais	37
5. CONCLUSÃO.....	38
REFERÊNCIAS BIBLIOGRÁFICAS	39

1. INTRODUÇÃO

O câncer continua sendo uma das doenças mais temidas e uma das principais chances de cura é o tempo para a detecção da doença: quanto antes o paciente for diagnosticado, maior sua chance de recuperação.

Em modo geral, a melhor forma de combater o câncer é prevenindo a doença. Hábitos saudáveis como a prática de exercícios, boa alimentação e vacinas em dia podem ser grandes aliados à sua prevenção. No caso de câncer de pele, a melhor forma de prevenção da doença é evitar grandes horas de exposição ao sol e o uso constante de protetor solar.

Segundo o Instituto Nacional de Câncer José Alencar Gomes da Silva – INCA, o câncer de pele é o mais diagnosticado frequentemente no Brasil, nos quais representam 30% de todos os tumores malignos já registrados no país. No pior dos cenários, existe o câncer de pele do tipo melanoma que é mais raro e mais mortal.

Diante esse cenário, o uso da tecnologia torna-se um grande aliado no combate a esse tipo de doença, podendo trazer grandes vantagens sobre a velocidade em que o paciente poderá iniciar seu tratamento (INCA, 2017).

1.1. Problema em Estudo

A ausência de uma segunda opinião sobre as lesões de pele, que muitas vezes é dada a partir de um outro profissional da área médica através de avaliações superficiais da lesão. Existem muitos softwares que analisam as imagens através de padrões estabelecidos por profissionais da área, mas poucos são utilizados em seu dia a dia.

1.2. Proposta de Solução

A proposta de solução para o problema citado é fazer com que uma rede neural consiga ser treinda a fim de que ela seja capaz de classificar as lesões de pele em duas categorias:

- Lesões benignas (*benign*): lesões que foram diagnosticadas como não sendo algum tipo de câncer.
- Lesões malignas (*malignant*): lesões nos quais foram diagnosticadas como sendo algum tipo de câncer de pele.

Figura 1. à esquerda, uma lesão benigna (não câncer) e, à direita, uma lesão maligna (câncer).



Fonte: Skin Cancer Foundation, 2018

A *Deep Learning*, ou Aprendizagem Profunda traduzindo para o português, é uma subárea da Inteligência Artificial que oferece os melhores resultados no que diz respeito aos sistemas inteligentes. Os carros autônomos, sistemas de busca na Internet, dispositivos que conversam diretamente com usuários e outras aplicações que forma o “estado da arte” da tecnologia usam *Deep Learning* (DL) (LECUN et al, p. 436-444, 2015).

O objetivo deste trabalho é aplicar todo um cenário para que a *Deep Learning* possa auxiliar na detecção de câncer de pele, ajudando os profissionais da área a terem uma tomada de decisão mais segura e dando um início rápido ao tratamento e a cura de maior parte dos pacientes.

Para isso, foi necessário efetuar uma forma de submeter a rede neural à um treinamento através da utilização de imagens captadas por aparelhos de videodermatoscópio, nos quais são utilizados para capturar imagens para análise clínica com rico detalhamento da área da lesão.

O conjunto dessas imagens foram separados em 2 classificações que formam conjuntos de imagens, também conhecido como *sets*(COURSERA, 2017). Os *sets* serão utilizados para montar a estrutura do aprendizado da máquina, tendo as seguintes características:

- *Trainset*: É onde ocorre de fato o aprendizado da rede neural. Neste diretório existem outros 2 diretórios que correspondem cada classificação das imagens: um para as lesões benignas e outra para as lesões malignas, nos quais são armazenadas as suas respectivas imagens de lesões e que servem para ensinar a rede neural que aquelas imagens representam sua classificação correspondente. As somas das imagens nesses dois diretórios correspondem a 60% de todas as imagens que farão parte do treinamento da rede neural.

- *Testset*: Este diretório terá as características idênticas aos do *trainset* em sua estrutura separando os diretórios das lesões malignas e das lesões benignas, mas somente com 20% de todas as imagens coletadas. O seu propósito é que a rede neural possa realizar os testes do que foi aprendido no *trainset*. A partir daí a rede neural poderá informar ao usuário o quanto ela já aprendeu sobre este treinamento.


2. REVISÃO DA LITERATURA

Este capítulo abordará os estudos e pesquisas realizadas sobre o câncer de pele e a *deep learning*, mostrando que o câncer de pele possui seus tipos e sua detecção pode ser realizada através da observação da lesão, enquanto a *deep learning* pode aprender os padrões da doença e oferecer possíveis diagnósticos.

2.1. O câncer de pele

O câncer, em modo geral, é o nome dado à um conjunto de 100 doenças catalogadas devido ao crescimento desordenada da estrutura celular do organismo, podendo espalhar-se para outras áreas do corpo (chamada de metástase) e pode manifestar-se tanto na área interna quanto na área externa do organismo, ambas podem ser relacionadas.

Figura 2. a evolução de uma célula cancerígena



Fonte: Instituto Nacional de Câncer José Alencar Gomes da Silva, 2018.

Segundo o Instituto Nacional de Câncer – INCA (2018), há diversas formas de contrair esta doença. É bem comum se contrair esta doença através do próprio ambiente em que se vive, como longas horas de exposição ao sol que pode causar o câncer de pele, o tabagismo pode causar câncer de pulmão ou de outro órgão que compõe o sistema respiratório, e até mesmo alguns vírus podem causar a leucemia.

O câncer de pele é o tipo mais frequente no Brasil e correspondem a 30% de todos os tumores diagnosticados (INCA, 2018). Pode ser classificado em duas categorias: o melanoma e o não melanoma. O fato da pele ser o maior órgão do corpo humano e possuir

diversos tipos de células podem formar-se diversos tipos de câncer, mas todos eles são classificados como carcinoma.

2.1.1. Câncer de pele não melanoma

É o tipo de câncer com mais casos no país. Apesar da alta frequência em que é encontrado, o seu cenário de cura é bem favorável em relação às demais doenças. Pessoas acima dos 40 anos e com pele mais clara são mais propícias a ter esse tipo de câncer, enquanto pessoas com pele escura e crianças tendem a ser mais resistentes, exceto casos em que a pele já tenha algum tipo de fator patológico que desenvolva essa doença [4].

Segundo dados do Instituto Nacional de Câncer - INCA, a estimativa é que foram diagnosticados aproximadamente 165.580 novos casos de câncer de pele do tipo não melanoma no Brasil, sendo 85.170 dos casos encontrados em homens e 80.410 em mulheres. O número de mortes por este tipo de câncer no Brasil corresponde à 1.769, sendo 1.000 das vítimas eram homens e 769 mulheres.

2.1.2. Câncer de pele não melanoma

Apesar do câncer de pele corresponder a 30% de todos os casos de tumores do Brasil, o câncer de pele do tipo melanoma corresponde apenas a 3% de todos os casos de tumores encontrados na pele. Apesar de raro, é bem agressivo em estágios mais avançados devido à alta probabilidade de ocorrer metástase. Seu prognóstico pode ser positivo se encontrado no estágio inicial da doença, o que justifica a grande alta na taxa de sobrevivência dos pacientes nos últimos anos.

Segundo dados do Instituto Nacional de Câncer – INCA (2018), a estimativa é que foram diagnosticados aproximadamente 6.260 novos casos de câncer de pele do tipo melanoma no Brasil, sendo 2.920 dos casos encontrados em homens e 3.340 em mulheres. O número de mortes por este tipo de câncer no Brasil corresponde à 1.547, sendo 903 das vítimas eram homens e 644 mulheres.








2.1.3. Detecção do câncer de pele

Segundo o artigo publicado no Hospital A. C. Camargo (2018), quanto mais cedo é a detecção do câncer de pele, mais elevada é a chance de ter bons resultados mediante um tratamento, seja ele cirúrgico ou quimioterápico.

Para detectar previamente se uma lesão de pele é potencialmente um câncer, é preciso dar a atenção aos sinais de alerta logo em que perceber a presença de uma mancha,

ferida ou pinta na pele. Uma ferida no qual não cicatriza, coça, muda seu tom de cor e cresce com o tempo, são exemplos desses sinais.

Tabela 1. Características de uma lesão de pele cancerígena.

	Cresce de tamanho		Muda de cor
	Muda de textura		Tem bordas irregulares
	Coça		Sangra
	Não melhora em 4 semanas		

Fonte: Instituto Nacional de Câncer José Alencar Gomes da Silva, 2018.

Diante esse levantamento de características, podemos citar a regra do ABCDE da lesão, no qual consiste em classificar a lesão através de cinco características. Uma mesma pinta pode apresentar uma ou mais dessas categorias e quanto maior o número, maior o grau de suspeita de ser um tumor de pele. Alguns tumores malignos de pele, porém, fogem dessa descrição e o diagnóstico só poderá ser realizado por um médico através de exames mais profundos.

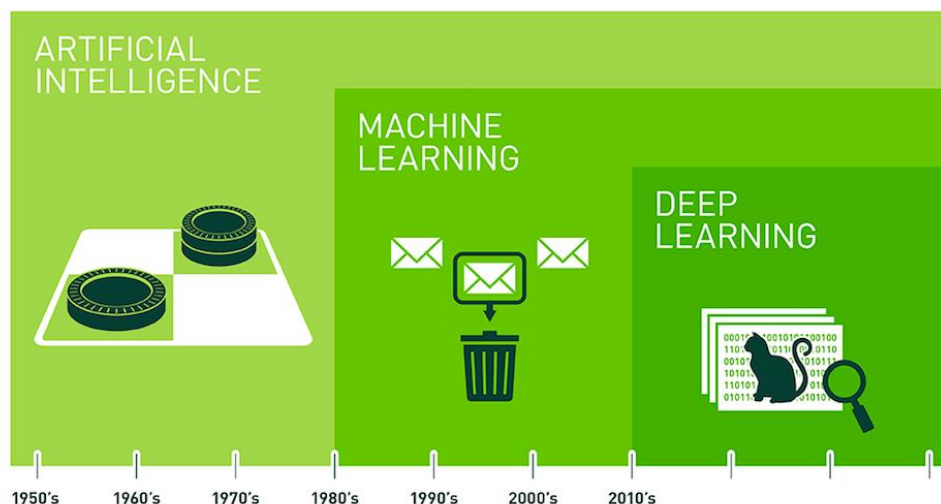
As características que compõem o ABCDE da lesão podem ser classificadas em:

- A – Assimetria: A forma de uma metade da lesão não corresponde à outra metade.
- B - Bordas irregulares: Suas bordas são irregulares, algumas vezes sem definição.
- C – Cor: Lesões cancerígenas na pele costumam ter cores não homogêneas, variando os tons de azul, marrom, vermelho e branco.
- D – Diâmetro: A lesão ultrapassa dos 6 milímetros de diâmetro.
- E – Evolução: A lesão muda de cor, tamanho e/ou forma.

2.2. A aprendizagem profunda

A *deep learning*, ou aprendizagem profunda, é uma subárea do aprendizado de máquina (*machine learning*) que é um estudo que surgiu a partir da inteligência artificial, que oferece resultados no que diz respeito aos sistemas inteligentes. Os carros autônomos, sistemas de busca na internet, dispositivos que conversam diretamente com usuários e outras aplicações que forma o “estado da arte” da tecnologia usam Deep Learning (DL) (LECUN; BEGIO, 2015)

Figura 3. a evolução da inteligência artificial



Fonte: Nvidia Developers, 2018

A proposta do Deep Learning é efetuar o aprendizado de uma máquina a partir de dado, no qual através dos mesmos segmentos nos quais são encontrados no sistema nervoso, especificados brevemente na rede de neurônios do cérebro.


Esse tipo de tecnologia só foi possível devido à dois fatores importantes na história da computação: a evolução dos hardwares de GPU e a elaboração das redes neurais artificiais.

2.2.1. Rede Neural Artificial

Segundo estudos apresentados pelo Instituto de Ciências Matemáticas e da Computação -ICMC, da Universidade de São Paulo – USP (2018), a rede neural artificial é a representação matemática de uma rede de neurônios de um mamífero inteligente, utilizando a experiência como aprendizado. Sua estrutura pode consistir em centenas de milhares de neurônios, enquanto à de um mamífero possui bilhões dele.

Para entender melhor o funcionamento da rede neural artificial, é preciso abordar a rede neural de um organismo vivo e inteligente, que possui uma extensa conexão entre os neurônios nos quais são responsáveis por todo o funcionamento do corpo através do sistema nervoso. A estrutura de um neurônio é consistida através dos dendritos, que é uma estrutura que consiste em terminais de entrada, um corpo central e o axônio, que são os terminais de saída.

Figura 4. Constituintes da célula neuronal



Fonte: ICMC – USP, 2018.

É através dessa estrutura que faz com que os neurônios possam se comunicar entre si, formando a estrutura de sinapse. A sinapse é onde ocorre a transmissão de impulsos nervosos em todo o sistema nervoso, no qual um neurônio envia uma substância neurotransmissora com saída através de seu axônio, que faz a conexão com os dendritos de outro neurônio, no qual se comunica com um terceiro neurônio e assim adiante até criar todo o sistema nervoso do organismo. Um neurônio pode realizar de 1 mil a 10 mil sinapses, sendo que o corpo humano pode efetuar aproximadamente $10E14$ sinapses, tendo um sistema de rede neural extremamente grande e complexa.


Uma rede neural é formada por unidades de processamento que estão conectadas através de canais de comunicação. Cada canal de comunicação possui um valor de peso no qual determinará a conexão com outra unidade de processamento. É através dessas conexões entre as unidades de processamento que é formada a rede neural artificial no qual, segundo a proposta elaborada por McCulloch e Pitts (1943), possuem as seguintes características operacionais:

1. Sinais chegam na entrada;
2. Cada sinal é multiplicado pelo peso de sua unidade de processamento, no qual o resultado indicará qual a saída/entrada de outra unidade;
3. O resultado do item anterior é aplicado à uma soma ponderada, no qual produzirá um nível;
4. É elaborado o resultado baseado no limite da unidade;

Essas redes neurais artificiais são separadas em 3 camadas, semelhante à uma célula neural. As camadas são compostas por:

1. Camada de entrada: a apresentação dos dados;
2. Camada intermediária (ou camada oculta): onde é realizado o processamento;
3. Camada de saída: apresentação do resultado;

Figura 5. Exemplo de funcionamento de um tipo de Rede Neural Artificial



Fonte: UFCG, 2011.

É através dessa estrutura de redes neurais que se encontra a capacidade da máquina aprender através do estabelecimento de padrões dos dados. Para que isso ocorra com sucesso, é necessário estabelecer planos de como os dados serão apresentados e analisados pela rede neural, aumento o seu desempenho conforme ela vai recebendo esses dados. O aprendizado ocorre quando a rede neural consegue generalizar os padrões através dos dados apresentados.

Uma forma de fazer com que a rede neural possa efetuar o aprendizado com eficácia, podemos separá-lo em 3 classificações:

1. Aprendizado supervisionado: é quando a rede neural é informada de qual é o resultado esperado após as análises dos dados;
2. Aprendizado não supervisionado: é o oposto ao Aprendizado supervisionado, onde não é informado qual o resultado esperado;
3. Reforço: existe alguém no qual é responsável por avaliar o resultado da rede neural.

Teremos neste trabalho a apresentação de imagens de lesões que se classificam como benignas (não-câncer) e malignas (câncer), no qual caracteriza a rede neural artificial no aprendizado supervisionado.

Com isso, o algoritmo de redes neurais poderá perceber os padrões do ABCDE do câncer de pele e poderá ser um grande aliado para a percepção desse tipo de doença.

2.2.2. Rede Neural Convulocional


Dentro do contexto da inteligência artificial, encontramos a rede neural convolucional (do inglês *convolutional neural network*, também denominada *CNN* ou *ConvNet*) que é vastamente utilizada no aprendizado de máquina através do processamento de imagens digitais.

Com esse tipo de rede neural, a máquina é capaz de reconhecer imagens e identificar objetos, animais, pessoas e lugares. Para o cérebro humano é fácil efetuar o reconhecimento através de imagens devido à bilhões de anos de evolução do cérebro para ter essa percepção. Para a máquina, isso torna-se mais complexo devido à ausência de uma evolução de sua rede neural. Por exemplo: quando olhamos a figura de uma árvore ou de uma rocha, não precisamos de um estudo consciente para deduzir o que aquela figura representa, diferente do que a máquina interpreta.

Para que isso seja possível, a máquina deve passar por treinamentos de aprendizagem no reconhecimento de imagens para conseguir classificar as figuras e saber deduzir o que ela representa.

A máquina consegue trabalhar semelhante ao cérebro humano ao reconhecer uma imagem. Ao analisar as imagens, ela converte essas imagens em matrizes através dos quadrantes (*pixeis*) das imagens e, através de banco de dados com outras imagens já matriciadas, estabelecer padrões e compará-los até deduzir um resultado no qual faz mais sentido (RAVINDRA et al., 2018).

Figura 6. Classificação da imagem



Fonte: InfoQ, 2018

O processo do cálculo da convolução é feita em duas etapas (HOCHULI, 2018):

- Processamento da Imagem: a rede neural convolucional analisa as propriedades da imagem e efetua as bordas, filtros e cores da imagem;
- Elaboração do Kernel: Tamanho, salto/passo, pesos, etc. Todo kernel possui um núcleo, estabelecido através do seu tamanho.

Por ora, teremos o passo a passo do processo de aprendizado de máquina:

1. A imagem é aberta pela máquina. Dá-se o início ao aprendizado da máquina.
2. Conversão para tons de cinza é realizada para a simplificação do processamento da imagem.
3. É realizada a elaboração de uma função dos tons representado. Essa função representa uma matriz que possui o eixo vertical que representa a medida do tom preto ao tom branco, considerando 0 para preto e 250 para branco. O eixo horizontal representa uma das linhas horizontais da imagem, em pixels.
4. Simplificando a nossa função, poderemos elaborar a simplificação do gráfico da função, no qual a média dos tons pode ser representado em zero. Essa simplificação também é conhecida como *downsampling*. Os valores abaixo de zero são tons mais escuros enquanto os tons mais claros são maiores que zero.

5. A partir dessa simplificação, a rede neural pode fazer a convolução das imagens, no qual é definida como o Kernel da convolução, no qual está definida em 3 pixels.
6. A convolução é a operação entre duas funções, no qual o resultado será uma única função gerada a partir da operação de unificação das funções. O processamento da convolução é dada a partir do posicionamento do núcleo do kernel com a outra função, e elaborada a operação no qual K é a posição do pixel no Kenel e M é a posição do pixel na fórmula:

$$\Sigma(K \times M)$$
7. Utilizando a função citada, é sobreposta a função do kernel com a função da imagem, utilizando o núcleo do kernel como referência no posicionamento.
8. Com o kernel, a convolução irá prosseguir pela função da imagem até que se complete todo o caminho da imagem, sempre utilizando o seu núcleo como parâmetro.
9. É gerada a função resultante. Através dessa função resultante é gerada a imagem resultante.
10. É destacado os pontos máximos da função resultante, no qual é o ponto chave para destacar quais os padrões da imagem estudada.

Nesse caso, temos a exclusão do estudo das margens, pois elas não se encaixam nos núcleos estabelecidos.

Com as redes neurais convolucionais, podemos fazer tarefas mais simples, como organizar fotos de pessoas de um banco de dados de uma escola, efetuar um catálogo das raças de cachorros através de um banco de imagens, dentre outros. No caso deste trabalho, é através do processamento das imagens de lesões, pintas e manchas na pele, previamente classificadas, que a máquina poderá efetuar um aprendizado do que é um câncer de pele ou não.

2.3. Soluções semelhantes

A informática está presente no dia a dia das pessoas como um todo, e na medicina não é diferente. Soluções para diagnósticos clínicos são utilizados o tempo todo, inclusive na detecção de vários tipos de câncer. Para o câncer de pele, existem algumas soluções que são comercializadas no mercado. Algumas delas são:

Unidade Biomap (2018): Desenvolvida por uma empresa situada em São José dos Campos, interior de São Paulo, a unidade Biomap oferece recursos que proporcionam um

ambiente adequado para que possa realizar o procedimento de dermatoscopia digital. Além disso, a unidade possui um software no qual permite-se analisar o ABCDE da lesão de pele, tendo a capacidade de gerar um diagnóstico para a doença. Não foram encontradas evidências da utilização de *deep learning* ou quaisquer utilizações de aprendizado de máquina no *software*.

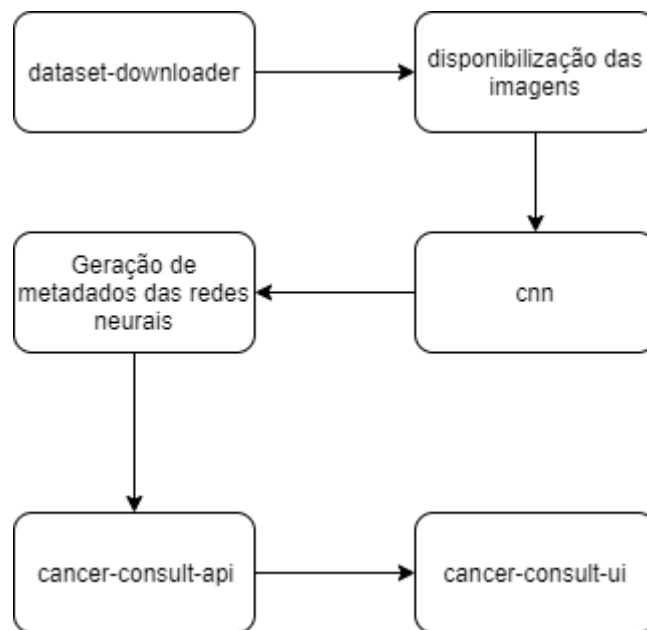
Utilização da CNN, na Universidade de *Stanford* (ESTEVA et al., 2018): alunos da Universidade de Stanford, nos Estados Unidos, desenvolveram uma solução de software utilizando a arquitetura CNN, também abordada neste artigo, para a detecção e diagnóstico de câncer de pele. Nesse software, desenvolvido na biblioteca de aprendizado de máquina *Tensorflow*, elaborada pela empresa americana Google, o software é capaz de elaborar diagnósticos de câncer de pele ao analisar as imagens originadas através de um dermatoscópio digital.

3. DESENVOLVIMENTO DO TRABALHO

3.1. Arquitetura do sistema

A arquitetura do sistema será separada em 4 sistemas: a ingestão dos dados (*dataset-downloader*), o treinamento das redes neurais (*cnn*), a disponibilização da rede treinada em uma *API Rest* (*câncer-consult-api*) e a interface de usuário para enviar alguma imagem para ser classificada pelas redes neurais (*câncer-consult-ui*).

Figura 7. Fluxo da arquitetura do sistema



3.2. Ingestão dos dados (*dataset-downloader*)

A estrutura dos dados que serão apresentados ao aprendizado de máquina são imagens digitais vindas de fotografias tiradas a partir de aparelhos chamados vídeodermatoscópio. Para o sucesso do aprendizado da máquina é necessário que as imagens sejam de uma qualidade boa, levando em consideração o tipo de equipamento utilizado e a resolução delas.

Figura 8. Videodermatoscópico sendo utilizado para captura de imagens



Fonte: Picbear, 2019

As imagens utilizadas neste trabalho foram adquiridas no repositório de imagens da *ISIC - International Skin Image Collaboration*, no qual possui um vasto repertório de imagens com diversas categorias de lesão de pele, incluindo as categorias de imagens de lesões diagnosticadas com câncer de pele (benigno) ou não (maligno).

Para realizar o *download* dessas figuras, foi portal do *ISIC* disponibiliza uma *API Rest* para que possamos efetuar o *download* das imagens e de seus metadados. Os metadados da imagem são estruturados em arquivos *JSON* no qual contém informações sobre a lesão e o paciente: idade, se possui histórico de melanoma na família, se é benigno ou maligno e o tipo da doença.

A *API* possui diversos *endpoints* - que estão relacionados na Tabela 2 – que mantém um fluxo de pesquisa e coleta dessas imagens. O primeiro *endpoint* consiste em uma lista com os *ids* dessas imagens, no qual é através desses *ids* que é possível coletar o seu metadado e, por fim, a imagem em arquivo.

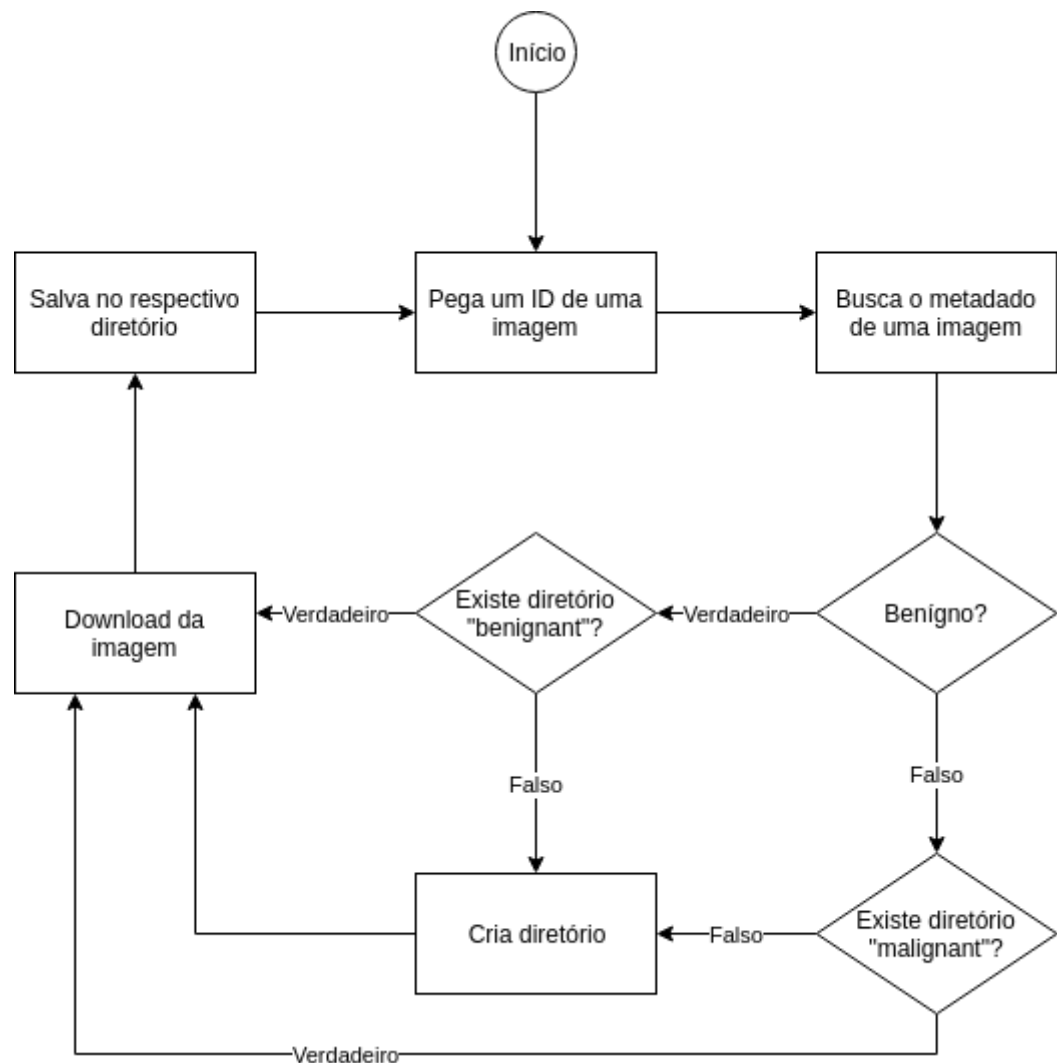
Tabela 2. Relação dos endpoints utilizados na API do ISIC.

<i>Endpoint</i>	Método	Tipo de resposta
https://isic-archive.com/api/v1/image	GET	<i>JSON</i> com uma lista de <i>ids</i> das imagens.
https://isic-archive.com/api/v1/image/{id}	GET	<i>JSON</i> com o metadado da imagem.
https://isic-archive.com/api/v1/image/{id}/download	GET	Imagem em formato <i>JPEG</i> .

Fonte: Autor, 2019

Para efetuar o *download* e classificação dessas imagens, foi desenvolvido um módulo chamado *dataset-downloader* utilizando a linguagem *Python* para que efetuasse requisições nesta *API Rest*, filtrasse o tipo de lesão (benigna e maligna) através da utilização dos metadados e salvasse-as em seus respectivos diretórios. O programa em *Python* contou com a interação com a biblioteca *requests* para efetuar essa comunicação com essa *API*. O fluxo de coleta dessas imagens está representado na Figura 9.

Figura 9. Fluxograma da ingestão de dados



Fonte: Autor, 2019

No total foram efetuados o download de 2600 imagens, sendo 1300 de imagens de fotos de lesões nos quais a presença do câncer foi confirmada e outras 1300 imagens de fotos nos quais foram descartadas as possibilidades de câncer de pele. Todas essas imagens geraram um volume de 15GB em um arquivo de extensão zip.


3.3 Treinamento das redes neurais (cnn)

Para que o treinamento da rede neural seja realizado, utilizamos alguns recursos de algoritmos de redes neurais encontrada na biblioteca do *Deeplearning4J*.

A estrutura básica de um algoritmo de redes neurais consiste na emulação de neurônios artificiais no qual efetuam a classificação do resultado do processamento através de um peso. Cada neurônio conecta-se com outro e passa este valor de peso para que o próximo o utilize para guiar-se com o aprendizado. Este processo é chamado de

backpropagation e é repetido várias vezes até que se obtenha um resultado confiável de acurácia. Este processo pode ser representado na figura abaixo.

Figura 10. Esquema de *backpropagation*




Fonte: Autor, 2017.

Para a realização deste trabalho foram utilizados dois modelos de redes neurais: A LeNet e a AlexNet. Ambas as redes neurais são atendidas pelo Deeplearning4j e apresentam suas características individuais para seu aprendizado. Cada rede neural passou por um processo de aprendizado e gerou um arquivo de extensão .zip contendo o seu metadado para posterior utilização.

3.3.1. Modelo LeNet

As redes neurais funcionam basicamente através de suas múltiplas camadas de neurônios e através de seus algoritmos de *backpropagation*. O que difere uma da outra é sua arquitetura. A arquitetura utilizada neste projeto foi elaborada por Yann Lecun em 1998, o modelo de rede neural LeNet que é capaz de processar os padrões de imagens efetuando análise de *pixels* com extrema variância de e robustez. Segundo Yann Lecun, ela é capaz até mesmo de reconhecer caracteres feitos à mão.

Figura 11. rede neural treinada no modelo LeCun reconhecendo caracteres



Fonte: LeCun, 1998

Sua última versão é a LeNet-5, nos quais inspiraram até mesmo outros cientistas da computação a criarem outros tipos de modelos de redes neurais, como, por exemplo, a AlexNet feita por Alex Krizhevsky na Universidade de Toronto em 2012 (KRIZHEVSKY, 2012).

3.3.2. Gradiente descendente

Para realizar um aprendizado mais eficiente, podemos utilizar alguns algoritmos que podem efetuar a redução das funções e pesos nas iterações do algoritmo do aprendizado de máquina. Para isso, existe uma propriedade na rede neural chamada de *fine-tuning*, que visa montar um conjunto de configurações necessárias para a agilidade desse processo.

Logo que foi montada toda essa estrutura de algoritmos, podemos utilizar o conceito de “gradiente descendente”, no caso deste trabalho o escolhido foi o *Stochastic gradient descent*, no qual tem por finalidade utilizar as camadas intermediárias das redes neurais e um conjunto dessas redes. Dessa forma, a rede neural pode determinar quais os erros de dedução no aprendizado e repetir o estudo com mais eficiência através da troca de pesos. Isso é possível porque o *Stochastic gradient descent* é um algoritmo *backpropagation*, no qual faz com que os dados de entrada vão percorrendo camada por camada da rede neural até que, durante sua saída, compare-os com os resultados esperados.


Caso haja um erro com a comparação do resultado de saída com o resultado esperado, é recalculado os pesos e retro propagado até que se obtenha um cenário onde a acurácia aumenta significativamente.

3.4. *API Rest (cancer-consult-api)*

Para que possamos obter um sistema legível para que uma pessoa possa utilizá-lo, foi criada uma interface de usuário para que possa utilizar a rede neural treinada de forma mais simples e objetiva. A proposta levada foi o levantamento de uma *API Rest* comunicando com essa interface de usuário, para que o sistema seja capaz de receber uma imagem via protocolo *HTTP* (BERNERS-LEE, 1992), enviar para análise da rede neural, receber o resultado de acurácia e responder de volta para a interface de usuário.

A *API Rest* foi escolhida devido ao fato dela representar uma arquitetura *web* moderna que oferece uma dinâmica de tecnologias muito abrangente, pois não ficaria limitado à apenas um cliente (FIELDING et al, 2002). Existem diversas maneiras de implementar uma *API Rest*, porém, a escolhida para fazer parte deste projeto foi o *Spring* (GRAY, 2016).

Figura 12. Estrutura de uma API Rest



Fonte: DZone, 2017.

Ao montar o projeto em *Spring*, foi decidido utilizar a iniciativa do *Spring Boot*, pois possibilita a rápida inicialização do serviço da *API Rest* e deixando-o com alta disponibilidade e escalabilidade (ARLITT et al, 2001). Também existe outra vantagem da

utilização do *Spring Boot*, que é a rápida estruturação do projeto, no qual pode-se utilizar ferramentas como o *Spring Initializr* ou o *Setup My Project*.

Esta *API* disponibiliza um único *endpoint* para realizar o *upload* de um arquivo de imagem e retorna o resultado das avaliações realizadas nos metadados das redes neurais LeNet e AlexNet.

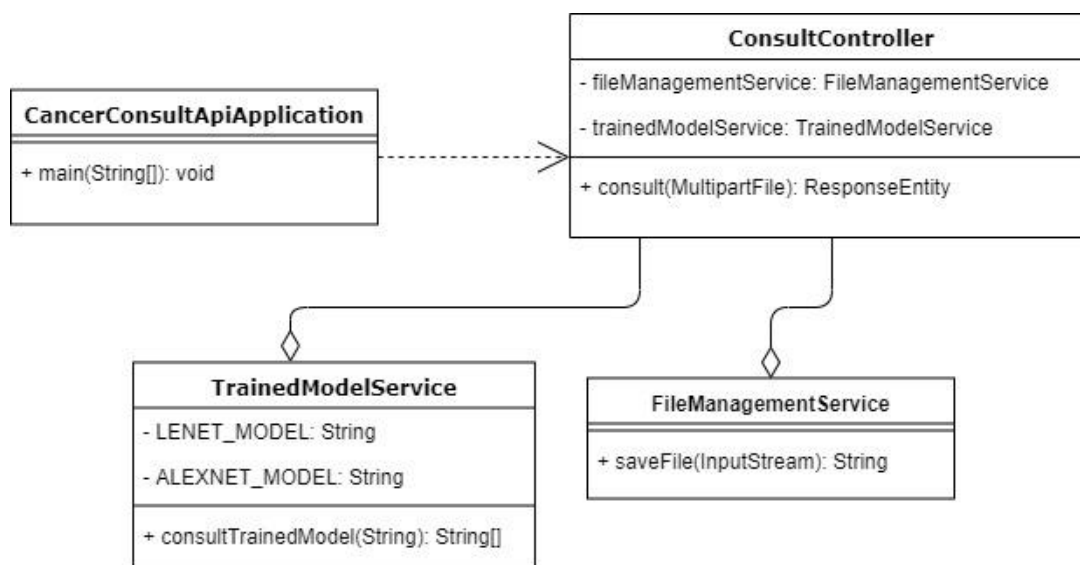
A estrutura desenvolvida nesta *API* segue o padrão *model/view/controller – MVC* (LEFF et al, 2001), apresentando as seguintes classes:

Tabela 3. classes do projeto cancer-consult-api

Classe	Descrição
CancerConsultApiApplication.java	Classe que inicia a aplicação.
ConsultController.java	Classe que possui o <i>endpoint</i> que será feito o upload da imagem.
FileManagementService.java	Classe responsabilizada para salvar a imagem no qual foi feito o upload.
TrainedModelService.java	Classe que envia a imagem para as redes neurais e retorna o resultado de suas consultas.

Estas classes também possuem uma relação que pode ser mostrada no seguinte diagrama de classe:

Figura 13. diagrama de classe do projeto cancer-consult-api



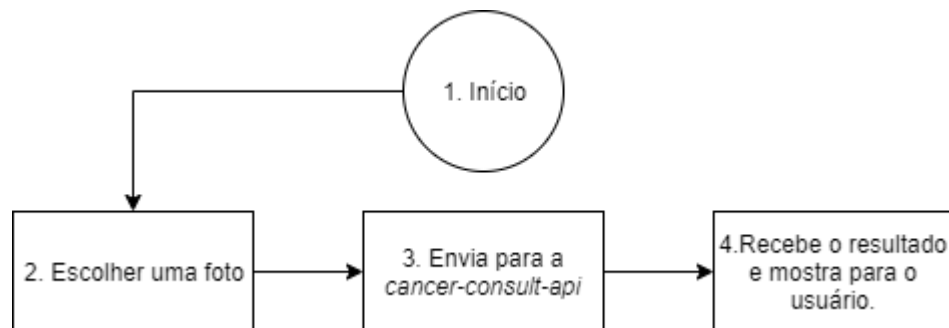
Fonte: autor, 2019

Ao iniciar esta aplicação, ela ficará disponível utilizando a porta 8080 do protocolo *Transmission Control Protocol – TCP* e a troca de informações é feita através do protocolo *HyperText Transfer Protocol – HTTP*.

3.5. Interface de usuário (*cancer-consult-ui*)

A interface web acessará um endereço web (*URL*) no qual um usuário poderá selecionar um arquivo contendo uma imagem em seu dispositivo e efetuar o *upload* para ser consultada no projeto *cancer-consult-api*. O fluxo da interface de usuário é:

Figura 14. Fluxo da interface web



Fonte: Autor, 2018.

1. O usuário entrará nessa interface através de um browser.
2. O usuário poderá escolher uma foto salva em seu dispositivo.
3. Através do método *HTTP POST*, a interface poderá enviar a imagem para a *API Rest*.
4. A *API Rest* responderá se é ou não um câncer de pele e qual o percentual de sua acurácia sobre essa resposta.

4. RESULTADOS E DISCUSSÕES

O grande desafio ao trabalhar com redes neurais é montar todo o cenário para uma utilização eficaz desta tecnologia. A montagem dos *sets*, a escolha das fontes das imagens, a qualidade das imagens e o modelo de rede neural escolhida são fatores que influenciam o seu sucesso.

A aplicação da utilização das redes neurais pode ser marcante no que podemos mostrar na sua potencial utilização. Sistemas inteligentes no qual utilizam este tipo de tecnologia trazem uma diferença enorme na experiência de seu usuário. Por outro lado, uma rede neural com uma ineficácia de seu aprendizado e com resultados sem sentido para aquilo que ela foi treinada, acabam caindo em desuso e, até mesmo, atrapalhando a utilização de seus usuários comprometendo todo o ciclo de vida do sistema.

A experiência de ter um sistema que pode enviar um resultado de um exame médico utilizando as redes neurais é algo que se pode aplicar a este tipo de experiência. O resultado de todo este projeto é um experimento na utilização de redes neurais na área médica, ainda não afirmando que ela de fato pode ser utilizada com confiança por profissionais da área com esse experimento.

Esta afirmação foi observada na comparação dos resultados do treinamento da rede neural, do resultado de seus testes realizados durante o processo de aprendizado de máquina e da sua utilização na prática. Neste cenário, foi observado que a rede neural treinada através do modelo LeNet possui uma acurácia de 77%, mas não consegue definir se uma imagem de lesão benigna no qual foi utilizada no seu treinamento é de fato uma lesão cancerígena ou não, dando um resultado de 60% de chances de não ser.

4.1. Outros *frameworks* de redes neurais

Java foi a principal linguagem com ênfase durante todo o curso de Tecnologia em Banco de Dados. Esse motivo a escolha do *DL4J* para a elaboração deste trabalho, porém existem outros tipos de *frameworks* com o mesmo propósito na comunidade, dentre eles o mais popular *Tensorflow*. Diante este cenário, seria válido testar a performance de outros *frameworks* e comparar suas acurácias com o *DL4J*.

5. CONCLUSÃO

As redes neurais fazem e farão ainda mais um importante papel na vida do ser humano. De certa forma, este trabalho pode contribuir para estudos futuros na aplicação deste tema na área da medicina. Isso nos leva a acreditar na possibilidade de elas participarem fortemente nas análises de imagens clínicas, como, por exemplo, análises de tomografias computadorizadas levando à um diagnóstico quase que instantâneo logo após o processamento das imagens coletadas.

No caso do câncer de pele, esse tipo de estrutura desenvolvida pode facilitar o acesso à um tipo de diagnóstico através da *API Rest* e da interface web. Qualquer pessoa poderia efetuar uma consulta nessa rede neural utilizando uma câmera simples, até mesmo de um dispositivo móvel. O acesso à essa informação pode levar a pessoa no qual está realizando a consulta a procurar um especialista no assunto para exames mais profundos de sua lesão, acelerando um possível diagnóstico e, caso realmente tenha este diagnóstico, um tratamento com início mais rápido e eficaz contra esta doença.

REFERÊNCIAS BIBLIOGRÁFICAS

Atonus Engenharia de Sistemas, **Unidade Biomap** - disponível em <http://www.biomap.com.br/>, acessado em 22/04/2018.

ARLITT, Martin; KRISHNAMURTHY, Diwakar; ROLIA, Jerry. Characterizing the scalability of a large web-based shopping system. *ACM Transactions on Internet Technology*, v. 1, n. 1, p. 44-69, 2001.

BERNERS-LEE, Tim et al. **World-wide web: The information universe**. *Internet Research*, v. 2, n. 1, p. 52-58, 1992.

CARVALHO, André Ponce de Leon F. de; **Redes Neurais Artificiais**, ICMC - USP, disponível em <http://conteudo.icmc.usp.br/pessoas/andre/research/neural/>, acessado em 22/04/2018.

COURSERA, **Depp Learning Specialization**, disponível em: <https://pt.coursera.org/specializations/deep-learning>, acessado em 08/11/2017.

ESTEVA, Andrea; KUPREL, Brett; NOVOA, Roberto A.; KO, Justin; SWETTER, Susan OM.; BLAU, Helen M.; THRUN, Sebastian; **Dermatologist-level classification of skin cancer with deep neural networks**, disponível em <https://www.nature.com/articles/nature21056>, acessado em 22/04/2018.

FIELDING, Roy T.; TAYLOR, Richard N. **Principled design of the modern Web architecture**. *ACM Transactions on Internet Technology (TOIT)*, v. 2, n. 2, p. 115-150, 2002.

GRAY, Tim. **What is the best Restful Web API Framework**. *Optimal Business Intelligence*, 2016, disponível em <https://optimalbi.com/blog/2016/07/07/whats-the-best-restful-web-api-framework-part-1/>, acessado em 09/12/2018.

Hospital A. C. Camargo; **ABCD do Câncer de pele** - disponível em: <http://www.accamargo.org.br/abcd-cancer-pele/>, acessado em 22/04/2018.

HOCHULI, André Gustavo; **Redes Neurais Convolucionais**, Departamento de Informática da Universidade Federal do Paraná - UFPR, disponível em http://www.inf.ufpr.br/aghochuli/caffe/CNN_PPT.pdf, acessado em 22/04/2018.

Instituto Nacional de Câncer (INCA), **Ações para a detecção do câncer de pele** - disponível em: http://www1.inca.gov.br/situacao/arquivos/acoes_detecc_ao.pdf, acessado em: 08/11/2017.

Instituto Nacional de Câncer (INCA), **Câncer de pele não melanoma** - disponível em: http://www2.inca.gov.br/wps/wcm/connect/tiposdecancer/site/home/pele_ao_melanoma, acessado em 22/04/2018.

Instituto Nacional de Câncer (INCA), **Câncer de pele melanoma** - disponível em: http://www2.inca.gov.br/wps/wcm/connect/tiposdecancer/site/home/pele_melanoma, acessado em 22/04/2018.

KRIZHEVSKY, Alex; SUTSKEVER, Ilya; HINTON, Geoffrey E. **Imagenet classification with deep convolutional neural networks**. In: *Advances in neural information processing systems*. 2012. p. 1097-1105.

Leff, A.; Rayfield; J.T.; **Web-application development using the model/view/controller design pattern.** In Proceedings fifth iee international enterprise distributed object computing conference, IEEE, p. 118-127, 2001.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. **Deep learning.** *Nature*, v. 521, n. 7553, p. 436-444, 2015.

MCULLOCH, Warren S.; PITTS, Walter H; **A logical calculus of the ideas immanent in nervous activity.** Bulletin of Mathematical Biophysics, v. 5, p. 115 – 133, 1943.

RAVINDRA, Saravam; REIS, Poliana; **Como as redes neurais convolucionais realizam o reconhecimento de imagens;** InfoQ, disponível em <https://www.infoq.com/br/articles/redes-neurais-convolucionais>, acessado em 22/04/2018.

SPRING, **Spring-Boot** – disponível em <https://spring.io/projects/spring-boot>, acessado em 09/12/2018.

SPRING, **Spring Initializr** – disponível em <https://start.spring.io/>, acessado em 09/12/2018.